



Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Estado de México

Análisis y reporte sobre el desempeño del modelo.
Dataset: Breast Cancer Wisconsin (Diagnóstico), clasificación binaria

Inteligencia Artificial avanzada para la ciencia de datos

Roberd Otoniel Meza Sainz

A01801490

Grupo 601

Separación Train / Validation / Test

El dataset (569 muestras, 30 características numéricas) se dividió en tres conjuntos usando un muestreo aleatorio con semilla fija para reproducirlo. Se utilizó un 70% para entrenamiento, 15% para validación y 15% para prueba. El conjunto de entrenamiento se usó para ajustar los árboles, el de validación se empleó durante la experimentación para diagnosticar el bias y la varianza y el de prueba se evaluó una sola vez al final para reportar el desempeño real de generalización del modelo ya seleccionado.

Conjunto	Número de muestras	Proporción
Train	398	70%
Validation	85	15%
Test	86	15%


Diagnóstico del modelo base

Se entrenó un Random Forest base con hiperparámetros iniciales de `min_samples_split = 2`, `max_depth = 5` y 15 árboles. Para el diagnóstico de bias, varianza y nivel de ajuste, se midió el accuracy sobre train y validation, utilizando un umbral de gap (train - val) de 5% para determinar una varianza alta. Adicionalmente, una validación cruzada (5-fold) sobre el entrenamiento arrojó un promedio de 0.9595, respaldando la métrica de validación.

Indicador	Valor
Train accuracy	0.9975
Validation accuracy	0.9647
Gap (train - val)	3.28%
Diagnóstico de Bias	Bajo (train accuracy alto, aprox 99%)
Diagnóstico de Varianza	Baja (gap < 5%)
Nivel de ajuste	Fit (ajuste adecuado)

Argumentación

El bias se lee directamente del desempeño en train. Un accuracy de 99.75% indica que el modelo tiene la capacidad suficiente para capturar los patrones del dataset (bias bajo). La varianza se interpreta mediante el gap entre train y validation. Al ser de 3.28% < 5%, demuestra que el modelo generaliza consistentemente o varianza baja. Esta combinación resulta en un modelo bien ajustado sin underfitting ni overfitting.




Curva de aprendizaje variando la profundidad máxima (max_depth). Se observa underfitting en profundidades bajas (1-3). El punto de ajuste óptimo (fit) se alcanza en max_depth=6, donde el accuracy de validación llega a su pico máximo. A partir de max_depth=8, el accuracy de entrenamiento llega a 1.00 mientras que validación decae y se desestabiliza, evidenciando un aumento en la varianza (overfitting).

Regularización, bagging vs árbol individual

Para evaluar el efecto de la regularización, se comparó un árbol de decisión individual profundo (max_depth = 15) contra un Random Forest con los mismos parámetros de profundidad, pero aplicando bagging (muestreo bootstrap) y un submuestreo aleatorio de características con 15 árboles.

Modelo	Train	Validacion	Gap	Varianza
Árbol individual (max_depth=15)	1.0000	0.9647	3.53%	Media (3.53%)
Random Forest / bagging (max_depth=15, 15 árboles)	1.0000	0.9765	2.35%	Baja (2.35%)

El árbol individual profundo muestra un incremento en la varianza frente al base (gap de 3.53%). Sin embargo, el Random Forest con la misma profundidad reduce el gap a 2.35%. Esto confirma que el bagging actúa como la técnica de regularización del Random Forest: permite emplear árboles individuales más profundos (menor bias) al promediar los votos de modelos entrenados en distintas muestras, reduciendo significativamente la varianza del conjunto.



Evaluación final

Con el modelo regularizado seleccionado mediante los conjuntos de train y validation (bagging, max_depth = 15, 15 árboles), se realizó una evaluación sobre el conjunto de test, el cual nunca fue visto por el modelo durante el entrenamiento. Se comparó directamente contra el desempeño del modelo base en el mismo conjunto.

Métrica	Baseline (max_depth=5)	Regularizado (max_depth=15)
Accuracy	0.9302	0.9419
Precision	0.9706	0.9714
Recall (Sensibilidad)	0.8684	0.8947
Especificidad	0.9792	0.9792
F1 score	0.9167	0.9315
TP / TN / FP / FN	33 / 47 / 1 / 5	34 / 47 / 1 / 4

Conclusión

El modelo base (max_depth = 5) demostró un ajuste inicial adecuado, con bias y varianza bajos según los criterios establecidos. Al explorar una mayor complejidad (max_depth = 15), se evidenció que el riesgo de sobreajuste cae principalmente en el árbol individual. La implementación del bagging en el Random Forest funcionó como un regularizador natural,

permitiendo aprovechar la profundidad de los árboles para reducir el bias sin el costo asociado de una alta varianza.

Esta regularización resultó en una mejora tangible en el conjunto de prueba frente al base, elevando el accuracy global a 94.19% y, de manera crítica para un problema de diagnóstico médico, mejorando el recall de 86.84% a 89.47%, lo que significa una reducción directa en los falsos negativos.